Curso: Análisis Numérico

Guía de Estudio

Sistemas Lineales: Métodos Directos, Normas y Condicionamiento

Instructor: Imelda Trejo Lorenzo

Febrero–Marzo 2025

Abstract

Esta guía cubre los fundamentos teóricos y computacionales para resolver sistemas lineales $Ax = b$. El orden de presentación sigue la lógica del descubrimiento: primero resolvemos sistemas con métodos directos, observando que la estructura de A determina el método óptimo; luego desarrollamos las herramientas para medir y cuantificar esa diferencia (normas); y finalmente respondemos la pregunta de fondo: ¿cuándo podemos confiar en la solución obtenida? (número de condición). Cada sección incluye definiciones formales, resultados teóricos, ejemplos trabajados y código Python verificable.

Contents

1 Métodos directos para sistemas lineales **2**
1.1 Clases de matrices . . . 2
1.2 Eliminación Gaussiana con sustitución regresiva . . . 2
1.3 Factorización LU . . . 3
1.4 Método de Gauss-Jordan . . . 3
1.5 Factorización de Cholesky . . . 3
1.6 Tabla comparativa de métodos directos . . . 3

2 Normas vectoriales y matriciales **4**
2.1 Normas vectoriales . . . 4
2.2 Normas matriciales . . . 5

3 Número de condición y estabilidad numérica **7**
3.1 Cota de error por perturbación . . . 7
3.2 Número de condición . . . 8
3.3 κ_2 para matrices SPD . . . 8

4 Implementación en Python con NumPy/SciPy **8**
4.1 Normas vectoriales y matriciales . . . 8
4.2 Métodos directos: LU y Cholesky . . . 9
4.3 Número de condición y diagnóstico de estabilidad . . . 9
4.4 Comparación de costos: LU vs. Cholesky . . . 10

5 Resumen: flujo de decisión para resolver $Ax = b$ **11**

1 Métodos directos para sistemas lineales

Un método **directo** produce la solución exacta de $Ax = b$ —salvo errores de redondeo— en un número finito y predecible de operaciones aritméticas. Esto los distingue de los métodos iterativos, que construyen una sucesión de aproximaciones que converge a la solución.

La elección del método directo óptimo depende de la *estructura* de la matriz A. Comenzamos definiendo las clases de matrices relevantes.

1.1 Clases de matrices

Definición 1.1 (Matriz simétrica)**.** $A \in \mathbb{R}^{n\times n}$ es **simétrica** si $A^t = A$, es decir, $a_{ij} = a_{ji}$ para todo i, j.

Definición 1.2 (Matriz simétrica definida positiva (SPD))**.** $A \in \mathbb{R}^{n\times n}$ es **definida positiva** si $x^t Ax > 0$ para todo $x \in \mathbb{R}^n$, $x \neq 0$. Si además A es simétrica, se dice que A es **simétrica definida positiva** (SPD). Las matrices SPD tienen valores propios reales y positivos, son siempre no singulares, y aparecen con frecuencia en problemas de mínimos cuadrados, ecuaciones diferenciales elípticas y optimización convexa.

Teorema 1.1 (Criterio de Sylvester)**.** *A es SPD si y sólo si todos sus **menores principales** son positivos:*

$$\det(A_k) > 0 \quad \textit{para } k = 1, 2, \ldots, n,$$

donde A_k es la submatriz formada por las primeras k filas y columnas de A.

Definición 1.3 (Matrices triangulares)**.** A es **triangular superior** si $a_{ij} = 0$ para $i > j$; **triangular inferior** si $a_{ij} = 0$ para $i < j$. En ambos casos, $Ax = b$ se resuelve por sustitución directa en $O(n^2)$ operaciones.

Definición 1.4 (Dominancia diagonal estricta)**.** A es **estrictamente diagonal dominante** si $|a_{ii}| > \sum_{j\neq i} |a_{ij}|$ para cada fila i. Esta propiedad garantiza que A es no singular y que la eliminación Gaussiana sin pivoteo es numéricamente estable.

1.2 Eliminación Gaussiana con sustitución regresiva

La eliminación Gaussiana transforma el sistema aumentado $[A \mid b]$ en $[U \mid \tilde{b}]$ con U triangular superior, y luego resuelve $Ux = \tilde{b}$ por sustitución regresiva.

Pivotaje parcial. En el paso k, se intercambia la fila k con la fila $p \geq k$ que tiene el mayor elemento en valor absoluto en la columna k. Esto evita:

- **División por cero** cuando el pivote es exactamente cero.
- **Amplificación de errores de redondeo** cuando el pivote es pequeño en relación a otros elementos de la columna.

Observación 1.1. La eliminación Gaussiana sin pivoteo puede realizarse sin dividir por cero si y sólo si $\det(A_k) \neq 0$ para $k = 1, \ldots, n$. Si esta condición falla, el pivotaje es **indispensable**. En particular, toda matriz estrictamente diagonal dominante satisface esta condición.

1.3 Factorización LU

Definición 1.5 (Factorización LU)**.** La factorización LU con pivotaje parcial de $A \in \mathbb{R}^{n\times n}$ es $PA = LU$, donde P es una matriz de permutación, L es triangular inferior con unos en la diagonal, y U es triangular superior.

La ventaja central de LU no es el costo de factorización —el mismo $n^3/3$ que la eliminación directa— sino la amortización sobre múltiples sistemas. Una vez que se tiene $PA = LU$, resolver para cualquier nuevo b requiere solo dos sustituciones triangulares:

$$Ax = b \iff LUx = Pb \implies \begin{cases} Ly = Pb & O(n^2) \\ Ux = y & O(n^2) \end{cases}$$

Para k sistemas con la misma A y distintos $b_1, \ldots, b_k$, el costo total es $n^3/3 + kn^2$ en lugar de $kn^3/3$, diferencia enorme para k grande.

1.4 Método de Gauss-Jordan

Gauss-Jordan elimina tanto hacia abajo como hacia **arriba**, reduciendo $[A \mid I]$ a $[I \mid A^{-1}]$.

Observación 1.2. Para un único sistema, Gauss-Jordan es más caro: $n^3/2$ frente a $n^3/3$, un factor de 1.5. Se justifica cuando se necesita A^{-1} explícitamente, por ejemplo para calcular el número de condición $\kappa(A) = \|A\|\,\|A^{-1}\|$ (definido en la Sección 2).

1.5 Factorización de Cholesky

Definición 1.6 (Factorización de Cholesky)**.** Si A es SPD, existe una única factorización $A = LL^t$, donde L es triangular inferior con entradas diagonales positivas. Los elementos de L se calculan como:

$$l_{ii} = \sqrt{a_{ii} - \sum_{k=1}^{i-1} l_{ik}^2}, \qquad l_{ji} = \frac{1}{l_{ii}}\left(a_{ji} - \sum_{k=1}^{i-1} l_{jk} l_{ik}\right), \quad j > i.$$

Teorema 1.2 (Estabilidad de Cholesky)**.** *En la factorización de Cholesky, $l_{ii} \leq \sqrt{a_{ii}}$ para todo i: los elementos de L están acotados por las entradas de A. Esto contrasta con la eliminación Gaussiana sin pivoteo, donde los multiplicadores pueden crecer arbitrariamente. Cholesky es por tanto numéricamente más estable, y no requiere pivotaje.*

1.6 Tabla comparativa de métodos directos

Todos los métodos son $O(n^3)$; el coeficiente del término dominante determina la eficiencia práctica.

Método	**Condición de uso**	**Costo (término dominante)**	
		Mult/Div	Sumas/Restas
Gauss + sust. regresiva	A general	$\frac{n^3}{3}$	$\frac{n^3}{3}$
Factorización LU	A general	$\frac{n^3}{3}$	$\frac{n^3}{3}$
$\hookrightarrow$ resolver por sustituciones	por sistema adicional	n^2	n^2
Gauss-Jordan	A general, para A^{-1}	$\frac{n^3}{2}$	$\frac{n^3}{2}$
Cholesky $A = LL^t$	A SPD	$\frac{n^3}{6}$	$\frac{n^3}{6}$
$\hookrightarrow$ resolver por sustituciones	por sistema adicional	n^2	n^2

Conclusión. La pregunta que debe hacerse *antes* de calcular es: ¿qué estructura tiene A?

- A **general, un sistema:** Gauss con pivotaje. $n^3/3$.
- A **general, múltiples** b**:** factorizar LU una vez, resolver por sustituciones.
- A **SPD:** Cholesky. $n^3/6$, mitad que LU, más estable.
- **Se necesita** A^{-1}**:** Gauss-Jordan. $n^3/2$.
- A **tridiagonal / en banda:** algoritmo especializado $O(n)$.

2 Normas vectoriales y matriciales

Ahora que sabemos resolver $Ax = b$, necesitamos herramientas para *medir* errores y perturbaciones. Sin una forma precisa de cuantificar tamaños, no podemos responder preguntas como: ¿qué tan grande es el error en la solución cuando los datos tienen errores de medición? Esa herramienta es la norma.

2.1 Normas vectoriales

Definición 2.1 (Norma vectorial)**.** Sea V un espacio vectorial sobre $\mathbb{R}$. Una función $\|\cdot\| : V \to \mathbb{R}$ es una **norma** si satisface para todo $x, y \in V$ y $\alpha \in \mathbb{R}$:

1. $\|x\| \geq 0$, con $\|x\| = 0 \iff x = 0$ (positividad)
2. $\|\alpha x\| = |\alpha| \, \|x\|$ (homogeneidad)
3. $\|x + y\| \leq \|x\| + \|y\|$ (desigualdad triangular)

Definición 2.2 (Normas l^p en $\mathbb{R}^n$)**.** Para $x = (x_1, \ldots, x_n)^t \in \mathbb{R}^n$:

$$\|x\|_1 = \sum_{i=1}^{n} |x_i|, \qquad \text{(suma de valores absolutos)} \tag{1}$$

$$\|x\|_2 = \left(\sum_{i=1}^{n} x_i^2 \right)^{1/2}, \quad \text{(norma euclidiana)} \tag{2}$$

$$\|x\|_\infty = \max_{1 \le i \le n} |x_i|. \qquad \text{(norma del máximo)} \tag{3}$$

Ejemplo 2.1 (Cálculo de normas vectoriales)**.** Sea $x = (3, -4, 1)^t$:

$$\|x\|_1 = 8, \qquad \|x\|_2 = \sqrt{26} \approx 5.099, \qquad \|x\|_\infty = 4.$$

Se cumple $\|x\|_\infty \le \|x\|_2 \le \|x\|_1$ para cualquier $x \in \mathbb{R}^n$.

Teorema 2.1 (Equivalencia de normas en $\mathbb{R}^n$)**.** *Todas las normas en $\mathbb{R}^n$ son equivalentes: para cualquier par $\|\cdot\|_\alpha$, $\|\cdot\|_\beta$ existen $c_1, c_2 > 0$ con $c_1\|x\|_\alpha \le \|x\|_\beta \le c_2\|x\|_\alpha$ para todo x. En particular:*

$$\|x\|_\infty \le \|x\|_2 \le \sqrt{n}\,\|x\|_\infty, \qquad \|x\|_2 \le \|x\|_1 \le \sqrt{n}\,\|x\|_2.$$

La equivalencia garantiza que convergencia en una norma implica convergencia en todas. Sin embargo, el valor numérico de $\kappa_p(A)$ depende de p y siempre debe indicarse explícitamente.

2.2 Normas matriciales

Normas matriciales inducidas

Definición 2.3 (Norma matricial inducida)**.** Dada una norma vectorial $\|\cdot\|_p$, la norma matricial inducida de $A \in \mathbb{R}^{n\times n}$ es

$$\|A\|_p = \max_{x \ne 0} \frac{\|Ax\|_p}{\|x\|_p} = \max_{\|x\|_p = 1} \|Ax\|_p.$$

$\|A\|_p$ mide el **máximo factor de estiramiento** que A aplica a vectores unitarios. Esta definición garantiza automáticamente:

- **Compatibilidad:** $\|Ax\|_p \le \|A\|_p\,\|x\|_p$.
- **Submultiplicatividad:** $\|AB\|_p \le \|A\|_p\|B\|_p$.
- **Norma de la identidad:** $\|I\|_p = 1$ para todo p.

Radio espectral

El radio espectral es un concepto que recorre todo el curso: aparece en la convergencia de métodos iterativos (Tarea 6), en los círculos de Gershgorin y en el análisis asintótico de potencias de matrices.

Definición 2.4 (Radio espectral)**.** Sea $A \in \mathbb{R}^{n\times n}$ con valores propios $\lambda_1, \ldots, \lambda_n \in \mathbb{C}$. El **radio espectral** de A es

$$\rho(A) = \max_{1 \le i \le n} |\lambda_i|.$$

El radio espectral está definido para *cualquier* matriz cuadrada, no solo para matrices simétricas.

Para cualquier norma inducida se tiene $\rho(A) \leq \|A\|_p$. La demostración es directa: si $Av = \lambda v$ con $v \neq 0$, entonces $\|A\|_p\|v\|_p \geq \|Av\|_p = |\lambda|\|v\|_p$, luego $\|A\|_p \geq |\lambda|$; tomando el máximo sobre todos los valores propios se obtiene la cota. La igualdad $\|A\|_2 = \rho(A)$ es un resultado especial, válido únicamente cuando A es simétrica.

Teorema 2.2 (Fórmulas explícitas para normas inducidas)**.** *Para $A \in \mathbb{R}^{n\times n}$ con entradas a_{ij}:*

$$\|A\|_1 = \max_{1\leq j\leq n} \sum_{i=1}^{n} |a_{ij}| \quad \textit{(máxima suma de columna)}, \tag{4}$$

$$\|A\|_\infty = \max_{1\leq i\leq n} \sum_{j=1}^{n} |a_{ij}| \quad \textit{(máxima suma de fila)}, \tag{5}$$

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^tA)} \quad \textit{(raíz del mayor valor propio de } A^tA\textit{)}. \tag{6}$$

*La matriz A^tA es simétrica y semidefinida positiva para cualquier A, por lo que sus valores propios son reales y no negativos. Sus raíces cuadradas $\sigma_i = \sqrt{\lambda_i(A^tA)} \geq 0$ se llaman **valores singulares** de A; el mayor es $\|A\|_2$.*

*Cuando A es **simétrica**, el Teorema Espectral garantiza que sus valores propios son reales. En ese caso $A^tA = A^2$ con valores propios λ_i^2, los valores singulares son $|\lambda_i(A)|$, y*

$$\|A\|_2 = \max_i |\lambda_i(A)| = \rho(A) \qquad \textit{(solo cuando } A \textit{ es simétrica)}.$$

Observación 2.1. Regla mnemónica: "1" es vertical como una columna (suma por columnas); "∞" es horizontal como una fila (suma por filas). Calcular $\|A\|_2$ requiere valores singulares: costoso a mano, pero fundamental teóricamente.

Ejemplo 2.2 (Cálculo de normas matriciales)**.** Sea $A = \begin{pmatrix} 3 & 1 \\ -2 & 4 \end{pmatrix}$:

$$\|A\|_1 = \max\{|3| + |-2|,\ |1| + |4|\} = 5,$$
$$\|A\|_\infty = \max\{|3| + |1|,\ |-2| + |4|\} = 6.$$

Teorema 2.3 (Fórmula de Gelfand)**.** *Para cualquier $A \in \mathbb{R}^{n\times n}$ y cualquier norma matricial,*

$$\rho(A) = \lim_{k\to\infty} \|A^k\|^{1/k}.$$

*El radio espectral es la **tasa de crecimiento asintótico** de $\|A^k\|$: independientemente de la norma, $\|A^k\|$ crece como $\rho(A)^k$ para k grande. Tres consecuencias fundamentales:*

1. *$A^kx \to 0$ para todo $x \iff \rho(A) < 1$. Esta es la condición de convergencia de métodos iterativos $x^{(k+1)} = Tx^{(k)} + c$: el método converge $\iff \rho(T) < 1$.*

2. *$\rho(A)$ es la mejor cota inferior entre todas las normas inducidas: dado $\varepsilon > 0$, existe una norma con $\|A\| \leq \rho(A) + \varepsilon$.*

3. *Los círculos de Gershgorin localizan $\rho(A)$ en el plano complejo usando solo las entradas de A, sin calcular valores propios explícitamente.*

Observación 2.2. La fórmula de Gelfand unifica normas matriciales, radio espectral y convergencia iterativa. El hilo común: $\rho(A)$ gobierna el comportamiento de largo plazo de cualquier proceso que aplique A repetidamente.

La norma de Frobenius

Definición 2.5 (Norma de Frobenius)**.** Para $A \in \mathbb{R}^{m\times n}$:

$$\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \sqrt{\operatorname{tr}(A^tA)}.$$

$\|\cdot\|_F$ satisface los axiomas de norma y la submultiplicatividad, pero *no* es inducida por ninguna norma vectorial. El hecho distintivo es:

$$\|I_n\|_F = \sqrt{n} \neq 1 \quad \text{para } n > 1.$$

Esto modifica la cota inferior del número de condición definido con $\|\cdot\|_F$. Por submultiplicatividad:

$$\sqrt{n} = \|I\|_F = \|AA^{-1}\|_F \leq \|A\|_F \, \|A^{-1}\|_F,$$

de modo que $\kappa_F(A) \geq \sqrt{n}$, en contraste con $\kappa_p(A) \geq 1$ para normas inducidas.

Proposición 2.1 (Relación con valores singulares)**.** *Si A tiene valores singulares $\sigma_1 \geq \cdots \geq \sigma_r > 0$:*

$$\|A\|_F = \sqrt{\sigma_1^2 + \cdots + \sigma_r^2}, \qquad \|A\|_2 = \sigma_1, \qquad \|A\|_2 \leq \|A\|_F \leq \sqrt{r}\,\|A\|_2.$$

$\|A\|_F$ capta la *energía total* de todos los valores singulares, mientras que $\|A\|_2$ capta solo el mayor. En problemas de aproximación de rango bajo —truncar la SVD— $\|A\|_F$ mide cuánta información se pierde. Es además la única norma matricial que proviene de un producto interno: $\langle A, B\rangle = \operatorname{tr}(A^tB)$.

Ejemplo 2.3 (Norma de Frobenius vs. normas inducidas)**.** Sea $A = \begin{pmatrix} 3 & 1 \\ -2 & 4 \end{pmatrix}$:

$$\|A\|_F = \sqrt{9+1+4+16} = \sqrt{30} \approx 5.477.$$

Comparando: $\|A\|_1 = 5$, $\|A\|_\infty = 6$, $\|A\|_F \approx 5.477$. Para la identidad: $\|I_2\|_F = \sqrt{2} \neq 1$.

3 Número de condición y estabilidad numérica

Ya sabemos resolver $Ax = b$ eficientemente y ya tenemos las herramientas para medir errores. La pregunta final es: ¿cuánto puede amplificarse un error en los datos A, b hasta convertirse en error en la solución x?

3.1 Cota de error por perturbación

Considera el sistema perturbado $(A + \delta A)\hat{x} = b + \delta b$.

Teorema 3.1 (Cota de perturbación)**.** *Si A es no singular y $\kappa(A)\,\|\delta A\|/\|A\| < 1$, entonces*

$$\frac{\|\hat{x} - x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A)\dfrac{\|\delta A\|}{\|A\|}} \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right),$$

donde $\kappa(A) = \|A\|\,\|A^{-1}\|$.

La cota muestra que el error relativo en x puede ser hasta $\kappa(A)$ veces mayor que el error relativo en los datos. Esta cantidad es el número de condición.

3.2 Número de condición

Definición 3.1 (Número de condición)**.** Sea $A \in \mathbb{R}^{n\times n}$ no singular y $\|\cdot\|_p$ una norma inducida. El **número de condición** de A es

$$\kappa_p(A) = \|A\|_p \, \|A^{-1}\|_p \;\geq\; 1.$$

Si A es singular, $\kappa_p(A) = \infty$.

Geométricamente, $\kappa_p(A)$ es la razón entre el máximo y el mínimo factor de estiramiento de A. Una matriz con $\kappa(A) \approx 1$ transforma la esfera unitaria en un elipsoide casi esférico —todas las direcciones se estiran por igual. Una con $\kappa(A) \gg 1$ la aplana severamente: una perturbación en la dirección de mínimo estiramiento produce un error enorme en x.

Observación 3.1. Si $\kappa(A) \approx 10^k$, se pierden aproximadamente k dígitos de precisión. Con aritmética de doble precisión (≈ 16 dígitos), un sistema con $\kappa(A) \approx 10^{12}$ da resultados con apenas 4 dígitos confiables.

El mal condicionamiento es una propiedad del *problema*, no del algoritmo. Ningún método puede remediar una matriz intrínsecamente mal condicionada, aunque el escalamiento de filas o columnas puede reducir $\kappa(A)$ en la práctica.

Ejemplo 3.1 (Sistema mal condicionado)**.** El sistema $\begin{pmatrix} 1 & 2 \\ 1.0001 & 2 \end{pmatrix} x = \begin{pmatrix} 3 \\ 3.0001 \end{pmatrix}$ tiene solución exacta $x = (1,1)^t$. Al perturbar $1.0001 \to 0.9999$, la solución cambia a $\hat{x} = (-1,2)^t$: un cambio enorme ante una variación de 0.0002. El valor $\kappa_\infty(A) \approx 40002$ anticipa exactamente esta sensibilidad.

3.3 κ_2 para matrices SPD

Teorema 3.2 (κ_2 vía valores propios)**.** *Si A es SPD con valores propios reales positivos $0 < \lambda_1 \leq \cdots \leq \lambda_n$, entonces*

$$\kappa_2(A) = \frac{\lambda_n}{\lambda_1} = \frac{\lambda_{\max}}{\lambda_{\min}}.$$

Esto se sigue de $\|A\|_2 = \rho(A) = \lambda_{\max}$ (pues A es simétrica) y $\|A^{-1}\|_2 = 1/\lambda_{\min}$ (pues todos los valores propios son positivos).

Observación 3.2. Si $A = LL^t$ es la factorización de Cholesky, entonces $\kappa_2(A) = \kappa_2(L)^2$, equivalente a $\log \kappa_2(L) = \frac{1}{2}\log \kappa_2(A)$. L está a la mitad del camino entre A e I en escala logarítmica de condicionamiento.

4 Implementación en Python con NumPy/SciPy

4.1 Normas vectoriales y matriciales

Listing 1: Cálculo de normas con NumPy

```python
import numpy as np

x = np.array([3.0, -4.0, 1.0])
print(f"||x||_1   = {np.linalg.norm(x, 1):.4f}")        # 8.0
print(f"||x||_2   = {np.linalg.norm(x, 2):.4f}")        # 5.0990
print(f"||x||_inf = {np.linalg.norm(x, np.inf):.4f}")   # 4.0
```

```python

A = np.array([[3., 1.], [-2., 4.]])
print(f"||A||_1   = {np.linalg.norm(A, 1):.4f}")        # 5.0
print(f"||A||_inf = {np.linalg.norm(A, np.inf):.4f}")   # 6.0
print(f"||A||_2   = {np.linalg.norm(A, 2):.4f}")        # mayor valor singular
print(f"||A||_F   = {np.linalg.norm(A, 'fro'):.4f}")    # sqrt(30) ~ 5.477
```

4.2 Métodos directos: LU y Cholesky

Listing 2: Factorización LU y Cholesky con SciPy

```python
import numpy as np
from scipy import linalg

A = np.array([[3., 1., 6.],
              [2., 1., 3.],
              [1., 1., 1.]])
b = np.array([2., 7., 4.])

# Solucion directa (LU con pivotaje internamente)
x = np.linalg.solve(A, b)
print("Solucion:", x)

# Factorizacion LU explicita
# Nota: scipy usa A = P L U, no P A = L U como en clase
P_mat, L, U = linalg.lu(A)
print("\nP^t A - LU =\n", np.round(P_mat.T @ A - L @ U, 10))

# Cholesky (solo para matrices SPD)
A_spd = np.array([[4., -1., 0., 0.],
                  [-1., 4., -1., 0.],
                  [0., -1., 4., -1.],
                  [0.,  0., -1., 3.]])
b_spd = np.array([15., 10., 10., 10.])

L_chol = linalg.cholesky(A_spd, lower=True)
y      = linalg.solve_triangular(L_chol, b_spd, lower=True)
x_chol = linalg.solve_triangular(L_chol.T, y, lower=False)
print("Solucion (Cholesky):", np.round(x_chol, 6))
print("det(A) via Cholesky =", round(np.prod(np.diag(L_chol))**2, 6))
```

4.3 Número de condición y diagnóstico de estabilidad

Listing 3: Número de condición e impacto de perturbaciones

```python
import numpy as np

def diagnostico_condicion(A, b, delta_A=None, delta_b=None, norma=np.inf):
    """
    Calcula kappa_p(A) y estima la cota del Teorema de perturbacion.
    """
```

```python
    kappa = np.linalg.norm(A, norma) * np.linalg.norm(np.linalg.inv(A), norma)
    print(f"kappa(A) = {kappa:.4f}")
    if kappa > 1e4:
        print("ADVERTENCIA: sistema mal condicionado (kappa > 1e4)")

    if delta_A is not None and delta_b is not None:
        x     = np.linalg.solve(A, b)
        rel_A = np.linalg.norm(delta_A, norma) / np.linalg.norm(A, norma)
        rel_b = np.linalg.norm(delta_b, norma) / np.linalg.norm(b, norma)
        denom = 1 - kappa * rel_A
        if denom <= 0:
            print("Cota no aplica: kappa * ||dA||/||A|| >= 1")
            return
        cota       = (kappa / denom) * (rel_A + rel_b)
        x_pert     = np.linalg.solve(A + delta_A, b + delta_b)
        error_real = np.linalg.norm(x_pert - x, norma) / np.linalg.norm(x, norma)
        print(f"Cota teorica:  {cota:.6f}")
        print(f"Error real:    {error_real:.6f}")
    return kappa

A  = np.array([[1.0,    2.0], [1.0001, 2.0]])
b  = np.array([3.0, 3.0001])
dA = np.array([[0.0, 0.0], [-0.0002, 0.0]])
db = np.array([0.0, 0.0])

diagnostico_condicion(A, b, dA, db, norma=np.inf)
print("\nkappa_1   =", np.linalg.cond(A, 1))
print("kappa_2   =", np.linalg.cond(A, 2))
print("kappa_inf =", np.linalg.cond(A, np.inf))
```

4.4 Comparación de costos: LU vs. Cholesky

Listing 4: Tiempos reales vs. tamaño del sistema

```python
import numpy as np, time
from scipy import linalg

def generar_spd(n):
    B = np.random.randn(n, n)
    return B.T @ B + n * np.eye(n)

tamanos = [100, 300, 500, 800, 1000]
print(f"{'n':>6}  {'LU (s)':>12}  {'Cholesky (s)':>14}")
print("-" * 36)
for n in tamanos:
    A = generar_spd(n)
    t0 = time.time(); linalg.lu_factor(A);              t_lu   = time.time()-t0
    t0 = time.time(); linalg.cholesky(A, lower=True);  t_chol = time.time()-t0
    print(f"{n:>6}  {t_lu:>12.5f}  {t_chol:>14.5f}")
```

```python

print("\nCholesky es ~2x mas rapido que LU para SPD,")
print("confirmando el factor teorico n^3/6 vs n^3/3.")
```

5 Resumen: flujo de decisión para resolver $Ax = b$

Paso 1. Analiza A.

- ¿Es simétrica? ¿Definida positiva (Teorema 1.1)?
- ¿Tiene estructura especial: tridiagonal, en banda?
- ¿Cuántos sistemas con esta misma A deberás resolver?

Paso 2. Elige el método.

Situación	**Método**
A general, un sistema	Gauss con pivotaje parcial
A general, múltiples b	Factorizar LU; resolver por sustituciones
A SPD	Cholesky $A = LL^t$
Se necesita A^{-1}	Gauss-Jordan
A tridiagonal o en banda	Algoritmo especializado $O(n)$

Paso 3. Diagnostica el condicionamiento.

- Si $\kappa(A) \gg 1$, la solución puede ser numéricamente sin sentido, sin importar el método.
- Para A SPD: $\kappa_2(A) = \lambda_{\max}/\lambda_{\min}$ (Teorema 3.2).
- Si $\kappa(A)$ es grande, considera escalamiento.

Paso 4. Verifica.
Calcula $r = b - A\hat{x}$ y compara $\|r\|/\|b\|$. Un residuo pequeño no garantiza precisión cuando $\kappa(A)$ es grande.

Apéndice: tabla de propiedades de normas

Propiedad	**Fórmula**	**Condición**
Compatibilidad	$\|Ax\|_p \leq \|A\|_p \, \|x\|_p$	Norma inducida
Submultiplicatividad	$\|AB\| \leq \|A\| \, \|B\|$	Inducida y Frobenius
Norma de I	$\|I\|_p = 1$	Solo inducida
Norma de I (F)	$\|I_n\|_F = \sqrt{n}$	Frobenius
Cota κ_p	$\kappa_p(A) \geq 1$	Norma inducida
Cota κ_F	$\kappa_F(A) \geq \sqrt{n}$	Frobenius
$\kappa(I)$	$\kappa_p(I) = 1$	Norma inducida
κ ortogonal	$\kappa_2(Q) = 1$	Q ortogonal
κ_2 SPD	$\kappa_2(A) = \lambda_{\max}/\lambda_{\min}$	A SPD
Radio espectral	$\rho(A) \leq \|A\|_p$	Siempre
$\|A\|_2$ simétrica	$\|A\|_2 = \rho(A)$	A simétrica
Frobenius–SVD	$\|A\|_F^2 = \sum_i \sigma_i^2$	Siempre
$\|A\|_2$ vs $\|A\|_F$	$\|A\|_2 \leq \|A\|_F \leq \sqrt{r}\|A\|_2$	$r = \min(m, n)$
Cholesky–κ	$\kappa_2(A) = \kappa_2(L)^2$	$A = LL^t$ SPD