Análisis Numérico I — Primavera 2026

Instructor: Imelda Trejo — Última actualización: 18 de marzo de 2026

---

1. Mínimos cuadrados lineales

1.1. Motivación: cuando el sistema no tiene solución

En la práctica, los datos del mundo real rara vez producen sistemas lineales compatibles. Dado un sistema $Ax = b$ con $A \in \mathbf{R}^{m\times n}$, pueden presentarse tres situaciones:

- **Sobredeterminado** ($m > n$): más ecuaciones que incógnitas. En general $b \notin \mathrm{Col}(A)$ y no hay solución exacta.
- **Subdeterminado** ($m < n$): más incógnitas que ecuaciones. Si hay solución, hay infinitas.
- **Cuadrado con rango deficiente** ($m = n$, $\mathrm{rango}(A) < n$): el sistema puede ser incompatible o tener infinitas soluciones.

En todos estos casos la pregunta es: si no podemos resolver $Ax = b$ exactamente, ¿cuál es la mejor aproximación? La respuesta es minimizar el residuo.

Definición 1.1. *Sea $A \in \mathbf{R}^{m\times n}$ y $b \in \mathbf{R}^m$. Un vector $x^* \in \mathbf{R}^n$ es una* ***solución de mínimos cuadrados*** *de $Ax = b$ si minimiza la norma del residuo:*

$$\|Ax^* - b\|_2 \leq \|Ax - b\|_2 \qquad \forall\, x \in \mathbf{R}^n.$$

Equivalentemente, x^* minimiza $f(x) = \|Ax - b\|_2^2$.

La solución siempre existe aunque puede no ser única. La pseudoinversa de Moore-Penrose, introducida en la Sección 2, selecciona de forma canónica la solución de menor norma cuando hay infinitas. La conexión con ajuste de modelos lineales y regresión se verá en el tema siguiente.

Lecturas recomendadas. Los siguientes recursos ilustran la relevancia del problema en investigación actual. Se recomienda al menos una lectura antes de la siguiente clase.

- **Introducción conceptual (SVD y pseudoinversa).**
  Least Squares with the Moore-Penrose Inverse, Math for Machines.
  `https://mathformachines.com/posts/least-squares-with-the-mp-inverse/`
  Explicación geométrica accesible de la SVD y la pseudoinversa, con visualizaciones. Buen punto de entrada para conectar la teoría con intuición.

- **SVD, pseudoinversa y PCA (notas de curso universitario).**
  Least Squares, Pseudo-Inverses, PCA & SVD, University of Utah, CS6640.
  `https://www.sci.utah.edu/~gerig/CS6640-F2012/Materials/pseudoinverse-cis61009sl10.pdf`
  Notas concisas que cubren exactamente el contenido de esta sección más PCA, útil para quien quiera ver la extensión inmediata.

- **Aplicaciones de SVD: compresión, PCA, mínimos cuadrados.**
  Applications of SVD and Pseudo-inverses, Springer (cap. de libro).
  `https://link.springer.com/content/pdf/10.1007/978-1-4419-9961-0_14.pdf`
  Cubre pseudoinversa, compresión de datos y PCA desde la SVD. Directamente relevante para tesis en análisis de datos o imágenes.

- **Aplicación en tomografía computacional.**
  Comparison of algorithms for solving the least-squares problem with applications in computed tomography, UBC Open Collections (tesis de maestría).
  `https://open.library.ubc.ca/soa/cIRcle/collections/ubctheses/24/items/1.0398196`
  Muestra cómo el problema de mínimos cuadrados con rango deficiente aparece en reconstrucción de imágenes médicas, con comparación de algoritmos (CGLS, LSQR, regularización).

- **Hacia dónde va la investigación: de matrices a tensores.**
  Don't Matricize, Tensorize!, SIAM News.
  `https://www.siam.org/publications/siam-news/articles/don-t-matricize-tensorize/`
  Artículo de divulgación avanzada de SIAM que explica por qué "matricizar" datos multidimensionales (imágenes, señales neuronales, simulaciones científicas) destruye correlaciones estructurales valiosas. Presenta la SVD tensorial y sus generalizaciones (descomposición CP, Tucker, HOSVD, tensor-train) como la extensión natural de los métodos de esta clase. Lectura obligada para quien quiera trabajar con datos de alta dimensión en su tesis.

1.2. Caracterización por ortogonalidad (Kincaid & Cheney)

La clave geométrica es que Ax^* es la **proyección ortogonal** de b sobre $\mathrm{Col}(A)$, es decir, el residuo $r^* = b - Ax^*$ es ortogonal a toda columna de A.

Teorema 1.1 (Caracterización de la solución de mínimos cuadrados)**.** *Si $A^*(Ax^* - b) = 0$, entonces x^* es solución de mínimos cuadrados de $Ax = b$. La condición $A^*(Ax^* - b) = 0$ es equivalente a las **ecuaciones normales**:*

$$A^*A\,x^* = A^*b.$$

Demostración. De $A^*(Ax^* - b) = 0$ se concluye que $b - Ax^*$ es ortogonal al espacio columna de A. Sea y cualquier otro punto. Como $A(x^* - y) \in \mathrm{Col}(A)$, la ortogonalidad da:

$$\langle b - Ax^*, A(x^* - y)\rangle = 0.$$

Aplicando la regla de Pitágoras:

$$\|b - Ay\|_2^2 = \|b - Ax^* + A(x^* - y)\|_2^2 = \|b - Ax^*\|_2^2 + \|A(x^* - y)\|_2^2 \geq \|b - Ax^*\|_2^2.$$

Luego x^* minimiza $\|Ax - b\|_2$ sobre todo $y \in \mathbf{R}^n$. □

1.3. Existencia y unicidad

Teorema 1.2 (Existencia)**.** *El problema de mínimos cuadrados siempre tiene solución. El conjunto de soluciones es el conjunto* $\{x^* + z : z \in \mathrm{Nul}(A)\}$*, donde* x^* *es cualquier solución particular de las ecuaciones normales. Cuando* $\mathrm{Nul}(A) = \{0\}$ *este conjunto se reduce a un único punto; en caso contrario tiene la misma dimensión que* $\mathrm{Nul}(A)$*.*

Demostración. Primero mostramos que las ecuaciones normales $A^*Ax = A^*b$ siempre son compatibles. Basta verificar que $A^*b \in \mathrm{Col}(A^*A)$. Observemos que para cualquier $b \in \mathbf{R}^m$, el vector A^*b es de la forma $A^*b = A^*(b)$, es decir, pertenece a $\mathrm{Col}(A^*)$. Por otro lado, $\mathrm{Col}(A^*A) = \mathrm{Col}(A^*)$: en efecto, $A^*Az \in \mathrm{Col}(A^*)$ para todo z, y si $A^*w \in \mathrm{Col}(A^*)$ tomamos $z = w$ y notamos que $A^*(Aw) = A^*Aw \in \mathrm{Col}(A^*A)$. Luego $A^*b \in \mathrm{Col}(A^*) = \mathrm{Col}(A^*A)$ y el sistema es compatible; existe al menos una solución x^*.

Ahora caracterizamos todas las soluciones. Si $\hat{x}$ es otra solución de las ecuaciones normales, entonces $A^*A(x^* - \hat{x}) = 0$. Multiplicando por $(x^* - \hat{x})^*$:

$$0 = \langle A^*A(x^* - \hat{x}), x^* - \hat{x}\rangle = \langle A(x^* - \hat{x}), A(x^* - \hat{x})\rangle = \|A(x^* - \hat{x})\|_2^2,$$

luego $A(x^* - \hat{x}) = 0$, es decir, $x^* - \hat{x} \in \mathrm{Nul}(A)$. Definiendo $z = \hat{x} - x^*$, se tiene $z \in \mathrm{Nul}(A)$ y $\hat{x} = x^* + z$, lo que muestra que toda solución tiene la forma $x^* + z$ con $z \in \mathrm{Nul}(A)$. Recíprocamente, si $z \in \mathrm{Nul}(A)$ entonces $A^*A(x^* + z) = A^*Ax^* + A^*Az = A^*b + 0 = A^*b$, así que $x^* + z$ también es solución. Por tanto el conjunto de soluciones es exactamente $x^* + \mathrm{Nul}(A)$. □

Teorema 1.3 (Unicidad)**.** *Si* $\mathrm{rango}(A) = n$*, la solución de mínimos cuadrados es única:*

$$x^* = (A^*A)^{-1}A^*b.$$

Demostración. Si $\mathrm{rango}(A) = n$ entonces A^*A es invertible (se demostró en la tarea). Así, la unicidad se sigue de esta observación y de las ecuaciones normales. □

Observación 1.1. *La expresión* $A^+ = (A^*A)^{-1}A^*$ *es la pseudoinversa de Moore-Penrose cuando el rango es completo. Para el caso general (rango deficiente), la pseudoinversa se construye vía SVD y selecciona la solución de norma mínima; véase la Sección 2.*

1.4. Mal condicionamiento de las ecuaciones normales

Las ecuaciones normales son teóricamente correctas pero numéricamente problemáticas: el número de condición satisface

$$\kappa(A^*A) = \kappa(A)^2.$$

Formar A^*A explícitamente puede duplicar la pérdida de dígitos significativos. Para $\kappa(A) \approx 10^8$ en doble precisión (16 dígitos), $\kappa(A^*A) \approx 10^{16}$ hace la solución completamente inestable. La factorización QR resuelve este problema.

Kincaid & Cheney ilustran este fenómeno con un ejemplo sencillo en la página 280 que muestra cómo las ecuaciones normales pueden producir soluciones completamente erróneas aun cuando la matriz A parece bien comportada. *[Insertar ejemplo de Kincaid & Cheney, pág. 280.]*

1.5. Solución estable vía factorización QR

Sea $A \in \mathbf{R}^{m\times n}$ con $m \geq n$ y $\text{rango}(A) = n$. La factorización QR da $A = QR$, con $Q \in \mathbf{R}^{m\times n}$ de columnas ortonormales ($Q^*Q = I_n$) y $R \in \mathbf{R}^{n\times n}$ triangular superior.

R tiene diagonal positiva. En el proceso de Gram-Schmidt, la entrada diagonal $r_{kk} = \|\tilde{q}_k\|_2 > 0$ porque $\text{rango}(A) = n$ garantiza que ningún $\tilde{q}_k$ es el vector cero: si lo fuera, la columna a_k sería combinación lineal de las anteriores, contradiciendo la independencia lineal de las columnas de A. La positividad de la diagonal puede forzarse convencionalmente (cambiando el signo de la columna de Q y la fila de R correspondientes), y con esa convención la factorización QR con diagonal positiva en R es única.

Reducción a sistema triangular. Sustituyendo $A = QR$ en las ecuaciones normales $A^*Ax^* = A^*b$:

$$R^*Q^*QRx^* = R^*Q^*b \implies R^*Rx^* = R^*Q^*b.$$

Como R^* es invertible (su diagonal es positiva), se cancela R^* en ambos lados y la solución de mínimos cuadrados se obtiene resolviendo el sistema triangular superior:

$$Rx^* = Q^*b,$$

por sustitución regresiva. El número de condición involucrado es $\kappa(R) = \kappa(A)$, no $\kappa(A)^2$: la estabilidad se recupera.

1.6. Ejemplo numérico — rango completo

Resolver $\min_x \|Ax - b\|_2$ con:

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix}, \qquad b = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}.$$

Incompatibilidad del sistema

El sistema $Ax = b$ exige $x_1 + x_2 = 1$, $x_1 + 2x_2 = 2$, $x_1 + 3x_2 = 2$. Las dos primeras dan $x_2 = 1$, $x_1 = 0$, pero la tercera exigiría $0 + 3 = 2$. Contradicción: $b \notin \text{Col}(A)$.

Ecuaciones normales

$$A^*A = \begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix}, \qquad A^*b = \begin{pmatrix} 5 \\ 11 \end{pmatrix}, \qquad x^* = \begin{pmatrix} 2/3 \\ 1/2 \end{pmatrix}.$$

Verificación de la condición de ortogonalidad

$$r^* = b - Ax^* = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} - \begin{pmatrix} 7/6 \\ 5/3 \\ 13/6 \end{pmatrix} = \begin{pmatrix} -1/6 \\ 1/3 \\ -1/6 \end{pmatrix}, \qquad A^*r^* = \begin{pmatrix} 0 \\ 0 \end{pmatrix}. \checkmark$$

Solución vía QR

Aplicando Gram-Schmidt a las columnas de A:

$$Q = \frac{1}{\sqrt{6}} \begin{pmatrix} \sqrt{2} & -1 \\ \sqrt{2} & 0 \\ \sqrt{2} & 1 \end{pmatrix}, \qquad R = \begin{pmatrix} \sqrt{3} & 2\sqrt{3} \\ 0 & \sqrt{2/3} \end{pmatrix}.$$

Resolviendo $Rx^* = Q^*b$ por sustitución regresiva: $x^* = (2/3, 1/2)^T$. $\checkmark$

2. Rango deficiente y pseudoinversa de Moore-Penrose

Cuando $\text{rango}(A) = r < n$, el conjunto de soluciones de mínimos cuadrados es un subespacio afín de dimensión $n - r$. Para seleccionar una solución canónica se introduce la pseudoinversa de Moore-Penrose, cuya construcción natural pasa por la SVD.

2.1. Descomposición en valores singulares (SVD)

Teorema 2.1 (SVD)**.** *Toda matriz $A \in \mathbf{R}^{m\times n}$ con* $\text{rango}(A) = r$ *admite una descomposición*

$$A = U\Sigma V^T,$$

donde $U \in \mathbf{R}^{m\times m}$ y $V \in \mathbf{R}^{n\times n}$ son ortogonales, y $\Sigma \in \mathbf{R}^{m\times n}$ es diagonal con entradas

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0 = \sigma_{r+1} = \cdots$$

*Los σ_i se llaman **valores singulares** de A; las columnas u_i de U y v_i de V son los **vectores singulares izquierdos** y **derechos**.*

La SVD revela la estructura de A: las direcciones con $\sigma_i = 0$ forman $\text{Nul}(A)$; las r direcciones con $\sigma_i > 0$ forman $\text{Col}(A)$.

2.2. Pseudoinversa de Moore-Penrose

Definición 2.1. *La **pseudoinversa de Moore-Penrose** de A, denotada A^+, es la única matriz $A^+ \in \mathbf{R}^{n\times m}$ que satisface las cuatro condiciones de Penrose:*

(I) $AA^+A = A$,

(II) $A^+AA^+ = A^+$,

(III) $(AA^+)^T = AA^+$,

(IV) $(A^+A)^T = A^+A$.

Teorema 2.2. *Dada la SVD $A = U\Sigma V^T$, la pseudoinversa es $A^+ = V\Sigma^+U^T$, donde Σ^+ se obtiene transponiendo Σ e invirtiendo cada valor singular positivo:*

$$\Sigma^+ = \operatorname{diag}\left(\frac{1}{\sigma_1}, \ldots, \frac{1}{\sigma_r}, 0, \ldots, 0\right) \in \mathbf{R}^{n\times m}.$$

Demostración. Se verifica directamente que $V\Sigma^+U^T$ satisface las cuatro condiciones de Penrose usando la ortonormalidad de U y V, y las identidades $\Sigma\Sigma^+\Sigma = \Sigma$ y $\Sigma^+\Sigma\Sigma^+ = \Sigma^+$. □

2.3. Solución de norma mínima

Teorema 2.3. *La solución de **norma mínima** del problema de mínimos cuadrados $\min_x \|Ax - b\|_2$ es única y está dada por:*

$$x^* = A^+b = V\Sigma^+U^Tb = \sum_{i=1}^{r} \frac{\langle b, u_i\rangle}{\sigma_i}\, v_i.$$

Demostración. Todo minimizador tiene la forma $x^* + z$ con $z \in \operatorname{Nul}(A)$. Como $x^* = A^+b \in \operatorname{Col}(A^T) = \operatorname{Nul}(A)^\perp$, se tiene $\langle x^*, z\rangle = 0$ para todo $z \in \operatorname{Nul}(A)$, luego:

$$\|x^* + z\|_2^2 = \|x^*\|_2^2 + \|z\|_2^2 \geq \|x^*\|_2^2,$$

con igualdad solo si $z = 0$. Esto prueba la unicidad y la norma mínima. □

Observación 2.1. *La fórmula $x^* = \sum_{i=1}^{r} \frac{\langle b,u_i\rangle}{\sigma_i} v_i$ muestra que los valores singulares pequeños amplifican las componentes de b. Cuando A tiene rango numéricamente deficiente (valores singulares cercanos a cero pero no exactamente nulos), esto produce inestabilidad. La solución es la **SVD truncada**: dado un umbral $\tau > 0$, retener solo los términos con $\sigma_i > \tau$:*

$$x_\tau^* = \sum_{\sigma_i > \tau} \frac{\langle b, u_i\rangle}{\sigma_i}\, v_i.$$

Una elección práctica es $\tau = \varepsilon_{\text{maq}} \cdot \max(m,n) \cdot \sigma_1$, con $\varepsilon_{\text{maq}} \approx 2.2 \times 10^{-16}$ en doble precisión.

2.4. Ejemplo numérico — rango deficiente

Considerar:

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 0 & 1 & 1 \end{pmatrix}, \qquad b = \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix}.$$

La segunda fila es el doble de la primera, luego $\text{rango}(A) = 2 < 3$: hay infinitos minimizadores.

SVD y diagnóstico

Los valores singulares aproximados son:

$$\sigma_1 \approx 7.631, \quad \sigma_2 \approx 1.000, \quad \sigma_3 = 0.$$

El valor singular nulo confirma $\text{rango}(A) = 2$.

Solución de norma mínima

Con $r = 2$, usando $x^* = A^+ b = V\Sigma^+ U^T b$:

$$x^* \approx \begin{pmatrix} 0.071 \\ 0.214 \\ 0.286 \end{pmatrix}, \qquad \|Ax^* - b\|_2 = 0.$$

El residuo es cero porque $b \in \text{Col}(A)$: x^* es la solución exacta de menor norma. Todo vector $x^* + z$ con $z \in \text{Nul}(A)$ también resuelve el sistema pero con $\|x^* + z\|_2 > \|x^*\|_2$.

2.5. Implementación en R

Listing 1: Mínimos cuadrados: ecuaciones normales, QR y SVD en R

```
#         Ejemplo 1: rango completo


A <- matrix(c(1,1, 1,2, 1,3), nrow=3, byrow=TRUE)
b <- c(1, 2, 2)

# Ecuaciones normales
x_normal <- solve(t(A) %*% A, t(A) %*% b)
cat("Ecuaciones normales:  x* =", round(x_normal, 8), "\n")

# Verificacion de ortogonalidad del residuo
r <- b - A %*% x_normal
cat("A^T r (debe ser 0):  ", round(t(A) %*% r, 10), "\n")

# Factorizacion QR
x_qr <- qr.coef(qr(A), b)
cat("Via QR:               x* =", round(x_qr, 8), "\n")
```

```r

# Pseudoinversa (rango completo)
x_pinv <- solve(t(A) %*% A) %*% t(A) %*% b
cat("Pseudoinversa:       x* =", round(x_pinv, 8), "\n\n")


#         Ejemplo 2: rango deficiente


A2 <- matrix(c(1,2,3, 2,4,6, 0,1,1), nrow=3, byrow=TRUE)
b2 <- c(1, 2, 1)

# SVD
s <- svd(A2)
cat("Valores singulares:", round(s$d, 8), "\n")
cat("Rango numerico:", sum(s$d > 1e-10), "\n")

# Pseudoinversa via SVD
tol   <- 1e-10
d_inv <- ifelse(s$d > tol, 1/s$d, 0)
A2_plus <- s$v %*% diag(d_inv) %*% t(s$u)
x_svd <- A2_plus %*% b2
cat("Solucion norma minima (SVD):  x* =", round(x_svd, 8), "\n")
cat("Residuo ||Ax*-b||:            ",
    round(sqrt(sum((A2 %*% x_svd - b2)^2)), 12), "\n")
cat("Norma de x*:                  ", round(sqrt(sum(x_svd^2)), 8),
   "\n\n")

# Verificacion con ginv() del paquete MASS
library(MASS)
x_ginv <- ginv(A2) %*% b2
cat("ginv (MASS):  x* =", round(x_ginv, 8), "\n")
cat("Coincide con SVD manual:",
    isTRUE(all.equal(as.vector(x_svd), as.vector(x_ginv), tol=1e-8))
       , "\n")
```

2.6. Observaciones finales

Observación 2.2. *Los tres enfoques (ecuaciones normales, QR, SVD) son matemáticamente equivalentes cuando* $\operatorname{rango}(A) = n$*. La diferencia es numérica: QR es más estable que las ecuaciones normales, y SVD es el más robusto pero también el más costoso (*$O(mn^2 + n^3)$ *operaciones para* $m \geq n$*).*

Observación 2.3. *El número de condición* $\kappa(A) = \sigma_1/\sigma_r$ *cuantifica la sensibilidad de la solución: una perturbación* δb *produce un error relativo en* x^* *del orden* $\kappa(A)\,\|\delta b\|/\|b\|$*. Cuando* $\kappa(A) \gg 1$ *el problema es mal condicionado y la SVD truncada es necesaria.*

2.7. Ejercicios

1. Resolver $\min_x \|Ax - b\|_2$ para

$$A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}, \quad b = \begin{pmatrix} 6 \\ 5 \\ 7 \end{pmatrix}.$$

   Verificar la condición de ortogonalidad del Teorema 1.1 y confirmar que los resultados vía QR y vía ecuaciones normales coinciden.

2. Sea

$$A = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 2 & 1 \end{pmatrix}.$$

   Determinar rango(A), calcular la SVD en R y encontrar la solución de norma mínima de $\min_x \|Ax - b\|_2$ para $b = (1,0,1)^T$.

3. Demostrar que $A^+ = V\Sigma^+U^T$ satisface las cuatro condiciones de Penrose. ¿Por qué esto garantiza la unicidad de la pseudoinversa?

4. Comparar la estabilidad numérica de las ecuaciones normales y la factorización QR usando la **matriz de Hilbert** $H_{ij} = 1/(i + j - 1)$ para $n = 5, 8, 10$. Calcular $\kappa(H_n)$ y $\kappa(H_n^T H_n)$ en R y relacionar los resultados con el análisis de la Sección 1.4.

5. *(Problema aplicado.)* En tomografía computacional el sistema $Ax = b$ tiene $A \in \mathbf{R}^{m\times n}$ con $m \gg n$ y rango numéricamente deficiente. Investiga cómo la SVD truncada se utiliza para reconstruir imágenes y qué criterio se usa para elegir el umbral τ. Propón un ejemplo sintético en R y analiza el efecto de distintos valores de τ sobre la solución.

Referencias

- D. Kincaid & W. Cheney, *Numerical Analysis: Mathematics of Scientific Computing*, Brooks/Cole, 2002.
- R. Kress, *Numerical Analysis*, Springer, 1998.
- *Least Squares with the Moore-Penrose Inverse*, Math for Machines. `https://mathformachines.com/posts/least-squares-with-the-mp-inverse/`
- *Least Squares, Pseudo-Inverses, PCA & SVD*, University of Utah, CS6640. `https://www.sci.utah.edu/~gerig/CS6640-F2012/Materials/pseudoinverse-cis61009sl10.pdf`
- *Applications of SVD and Pseudo-inverses*, Springer. `https://link.springer.com/content/pdf/10.1007/978-1-4419-9961-0_14.pdf`

- *Comparison of algorithms for solving the least-squares problem with applications in computed tomography*, UBC Open Collections.
  https://open.library.ubc.ca/soa/cIRcle/collections/ubctheses/24/items/1.0398196
- *Don't Matricize, Tensorize!*, SIAM News.
  https://www.siam.org/publications/siam-news/articles/don-t-matricize-tensorize/